

【开源 AI 工具赛道】openKylin 赛题：面向 openKylin 操作系统的智能体长期记忆自动化评测 Benchmark 设计

1. 命题背景与痛点

随着大模型智能体逐步进入办公、研发和个人助理等场景，模型是否能够长期、稳定、可控地记住用户信息，已经成为影响智能体可用性的关键能力。长期记忆既包括应被保留的稳定信息，如偏好、路径和模板，也包括需要识别并排除的临时信息、敏感信息、风险指令和噪声。

当前，openKylin 开源生态中已支持主流智能体框架，如 KylinBot、kylin-agent、OpenClaw、Hermes Agent 等，但缺乏一套与之配套的、系统级的自动化评测工具，导致不同智能体在 openKylin 操作系统上的记忆能力难以量化比较。长期记忆评测仍存在明显不足：一是评测往往依赖人工检查，难以规模化；二是简单问答式验证项无法覆盖真实使用中的冲突更新、相似干扰和行动复用；三是自动评分容易出现语义偏移，难以稳定判断模型到底是“记住了”“误记了”还是“不该记却记了”。

因此，本赛题希望参赛者基于 openKylin 开源操作系统及生态，围绕通用智能体长期记忆能力，设计一套尽可能自动化、低人工介入、可复现、可扩展的评测 benchmark，用于衡量不同智能体在记忆写入、检索、更新、拒绝和任务复用等方面的能力。

2. 命题目标

参赛者需要基于 openKylin 操作系统环境设计一套通用长期记忆评测方案。方案应能将对话、记忆记录、行动轨迹、文件或其他运行产物统一组织为证据，并基于这些证据自动评估长期记忆能力。方案应重点覆盖以下能力：

- 长期保持：判断应保留的信息是否被稳定记住并在后续使用。
- 记忆调用：判断模型在后续交互中是否能正确调用相关信息。
- 动态更新：判断新信息出现后是否能够正确覆盖或修正旧信息。
- 相近区分：判断模型是否能识别相近信息之间的差异。
- 边界识别：判断不应长期保留或不应复用的信息是否被正确识别。
- 任务复用：判断模型在实际任务执行中是否能合理使用历史信息。

最终目标是形成一套能够自动产出多维指标的 benchmark，并优先在 openKylin 系统上完成验证，服务于 openKylin 社区智能体能力的持续评估与优化。

3. 交付要求

- a. **方案说明文档：**梳理长期记忆评测的测试目标、基本前提、数据生成方式、验证用例设计、结果收集以及自动评分完整流程。

核心要素：
 - **数据集设计：**给出可扩展的数据结构，能够覆盖不同类型的记忆样本及其相关验证项信息。
 - **自动评测方案：**说明如何在尽量少人工介入的情况下，根据运行证据对不同指标进行评分，并输出可解释的评分原因。
- b. **样例数据与样例结果：**提供少量示例任务、示例运行证据和示例评分结果，用于说明方案可执行。
- c. **可复现材料：**包括必要的脚本、配置、README 及具体实现代码，并确保所有代码均能在 openKylin操作系统上直接编译与运行。使评审方能够理解并复现核心流程。
- d. **工具化封装：**将评测流程打包为可在openKylin上一键运行的CLI命令行工具（或图形化界面），并支持导入不同智能体配置进行批量对比评测。建议产出.deb软件包格式，便于在 openKylin软件源中分发。
- e. **真实环境演示视频：**提供在openKylin桌面环境下，针对至少两款不同智能体运行评测，并产出多维对比雷达图的完整录屏（建议时长3~5分钟）。

4. 评审维度与 Scoring Standard

评审维度	权重	具体评分细则与指标要求
任务定义与通用性	15%	是否能面向不同智能体和不同证据来源进行评测；是否具备良好的迁移性。方案是否能与openKylin智能体操作系统架构良好集成，是否具备在openKylin生态中落地的实际价值。
数据设计质量	25%	是否覆盖多种长期记忆情形与不同证据来源；样本是否具有足够的区分度、覆盖面和扩展空间。
自动评分能力	25%	是否能够尽量减少人工审核；评分是否结构化、可解释；是否能区分正确记忆、遗漏、混淆、错误持久化和错误复用。
稳定性与可复现性	15%	同一输入下评测结果是否稳定；流程是否清晰；是否能支持批量运行和结果追踪。在openKylin标准环境下是否能稳定复现。

指标完整性	10%	是否能输出多维指标，而不仅是单一总分；是否能反映不同长期记忆能力的差异。
创新性与工程可落地性	10%	方案是否具有创新思路，同时具备实际落地和扩展价值。是否针对openKylin操作系统的架构特点进行了针对性优化，且具备实际落地和扩展价值。

评审时将重点关注方案是否能够在真实智能体运行证据上自动完成评测，并稳定区分不同模型或系统在长期记忆能力上的差异。